DAKAR INSTITUTE OF TECHNOLOGY

Master 2 — Intelligence Artificielle

BOOKSHOP

Plateforme Big Data — Pipeline Complet

Examen — Module : Technologie Big Data

Etudiants	**Hamady Ngansou SABALY** **Ousmane SOW** **Doudou Malick FAYE**
Enseignant	**Patrick NGOUNE**
Année académique	**2025 — 2026**
Date de rendu	**30 Avril 2026**

Stack Technique

Composant	Outil	Role
Data Warehouse	Snowflake	Stockage RAW, STAGGING, WAREHOUSE, MARTS
Transformation	DBT	14 modeles SQL (stg_*, dim_*, fact_*, obt_*)
Orchestration	Airflow	DAG quotidien 06h00 — Docker
Conteneurisation	Docker	DBT + Airflow conteneurises
Ingestion	Python	Pipeline PostgreSQL local vers Snowflake
Visualisation	Power BI	Dashboard 5 pages connecte à Snowflake
Versioning	GitHub	https://github.com/hamdilawo/bookshop-livrables.git

1. Contexte et Objectifs

Ce projet s'inscrit dans le cadre du module Technologie Big Data du Master 2 Intelligence Artificielle au Dakar Institute of Technology. L'objectif est de mettre en place un pipeline Big Data complet pour une librairie sénégalaise (BOOKSHOP), allant de l'ingestion des données brutes jusqu'a la visualisation analytique.

1.1 Enonce du projet

Une structure disposant d'un système de vente de livres souhaite exploiter ses données de vente. L'objectif est de faire les transformations nécessaires afin de produire des OBT (One Big Table) des ventes, permettant une analyse complète et optimisée.

1.2 Données utilisées

Elément	Quantité	Description
Catégories	10	Littérature, Droit, Sciences, Histoire, etc.
Livres	50	Livres avec ISBN, prix entre 5000-25000 FCFA
Clients	20	Clients avec noms et prénoms
Ventes	200	Lignes de vente sur l’année 2024
Factures	200	15% de factures partiellement payées

2. Architecture du Pipeline

L'architecture mise en place suit le modèle Médaillon Architecture avec 4 couches de transformation dans Snowflake, orchestrées par Apache Airflow et exécutées par DBT.

Couche	Schéma Snowflake	Contenu	Outil
Ingestion	RAW	5 tables brutes (category, books, customers, ven	tePsy,tfhaocntures)
Staging	RAW_STAGGING	5 vues stg_* avec conversion des dates YYYYM	MDDBDT
Warehouse	RAW_WAREHOUSE	3 dim_* + 5 fact_* avec enrichissements	DBT
Marts	RAW_MARTS	1 OBT obt_sales — jointure complète	DBT

2.1 Schema Snowflake

La base de données BOOKSHOP dans Snowflake contient les schémas suivants : RAW (données brutes), RAW_STAGGING (données préparées), RAW_WAREHOUSE (dimensions et faits), RAW_MARTS (OBT final). Les schémas STAGGING et WAREHOUSE vides correspondent aux schémas cibles natifs de DBT avant configuration du préfixe.

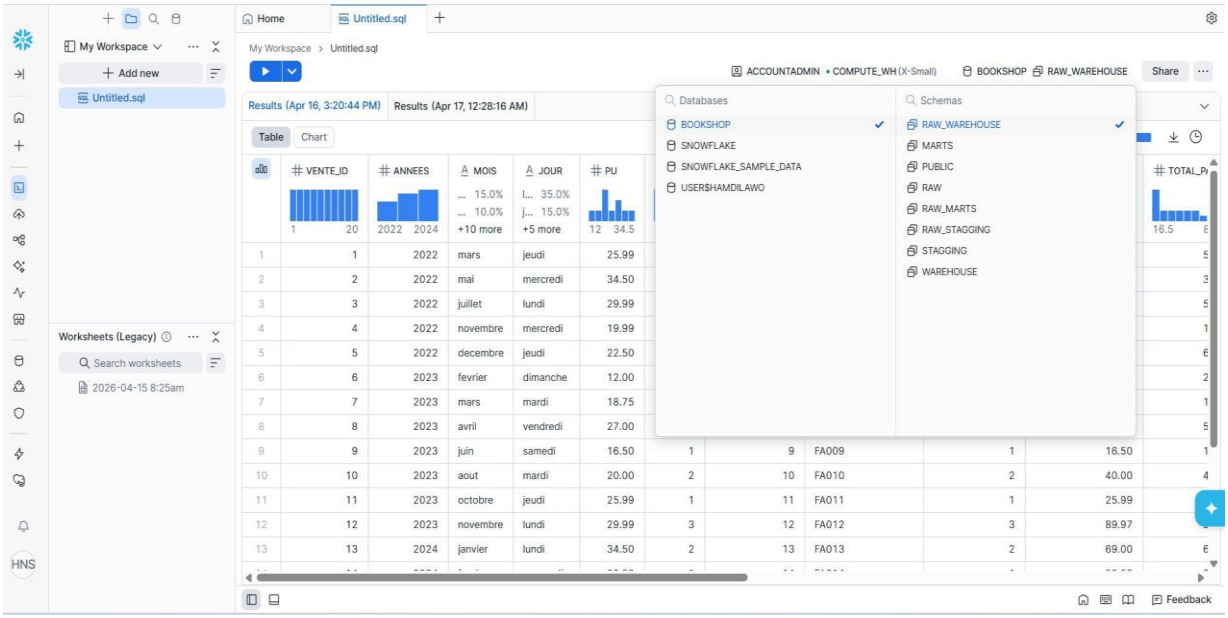

Figure 1 : Interface Snowflake — Base BOOKSHOP et ses schémas

3. Transformations DBT

DBT (Data Build Tool) est utilisé pour toutes les transformations SQL. Le projet contient 14 modèles organises en 3 couches. DBT est installé dans un conteneur Docker et se connecte a Snowflake via le profil bookshop configure dans profiles.yml.

3.1 Modèles Staging (5 modèles)

La couche Staging prépare les données brutes en convertissant les champs date_edit du format YYYYMMDD (varchar) vers le type DATE natif de Snowflake.

Modèle	Source	Transformation principale
stg_ventes	RAW.ventes	Conversion DATE_EDIT YYYYMMDD -> DATE
stg_factures	RAW.factures	Conversion DATE_EDIT YYYYMMDD -> DATE
stg_books	RAW.books	Copie directe
stg_category	RAW.category	Copie directe
stg_customers	RAW.customers	Copie directe

3.2 Modèles Warehouse (8 modèles)

Modele	Type	Enrichissements
dim_customers	Dimension	Ajout colonne NOM = first_name + last_name
dim_category	Dimension	Copie de stg_category
dim_books	Dimension	Copie de stg_books
fact_ventes	Fait	Ajout ANNEES (INT), MOIS (VARCHAR FR), JOUI (VARCHAR FR
fact_factures	Fait	Ajout ANNEES, MOIS, JOUR depuis DATE_EDIT
fact_books_annees	Fait agr.	Ventes par livre par année
fact_books_mois	Fait agr.	Ventes par livre par mois

)

3.3 Modèle Marts — OBT_SALES (1 modèle)

L'OBT (One Big Table) est la table finale qui joint toutes les tables du Warehouse en une seule vue analytique complète. Elle contient tous les champs nécessaires pour identifier une ligne de vente : informations vente, facture, livre, catégorie et client.

Source	Champs inclus
fact_ventes	id, années, mois, jour, pu, qte
fact_factures	id, code, qte_totale, total_amount, total_paid
dim_category	intitulé (catégorie)
dim_books	code, intitule, isbn_10, isbn_13

dim_customers	code, nom (prénom + nom)

3.4 Résultat DBT Run

L'exécution de dbt run produit 14 modèles avec succès en moins de 10 secondes. Le résultat final : PASS=14, WARN=0, ERROR=0 — Completed successfully.

```
13:18:57  Concurrency: 4 threads (target='dev')
13:18:57
13:19:00  1 of 14 START sql view model RAW_STAGGING.stg_books ........................... [RUN]
13:19:00  2 of 14 START sql view model RAW_STAGGING.stg_category ....................... [RUN]
13:19:00  3 of 14 START sql view model RAW_STAGGING.stg_customers ....................... [RUN]
13:19:00  4 of 14 START sql view model RAW_STAGGING.stg_factures ....................... [RUN]
13:19:01  2 of 14 OK created sql view model RAW_STAGGING.stg_category .................... [SUCCESS 1 in 1.16s]
13:19:01  3 of 14 OK created sql view model RAW_STAGGING.stg_customers ................... [SUCCESS 1 in 1.15s]
13:19:01  1 of 14 OK created sql view model RAW_STAGGING.stg_books ....................... [SUCCESS 1 in 1.16s]
13:19:01  5 of 14 START sql view model RAW_STAGGING.stg_ventes ........................... [RUN]
13:19:01  6 of 14 START sql table model RAW_WAREHOUSE.dim_category ....................... [RUN]
13:19:01  7 of 14 START sql table model RAW_WAREHOUSE.dim_customers ...................... [RUN]
13:19:01  5 of 14 OK created sql view model RAW_STAGGING.stg_ventes ...................... [SUCCESS 1 in 0.65s]
13:19:01  8 of 14 START sql table model RAW_WAREHOUSE.dim_books ......................... [RUN]
13:19:02  4 of 14 OK created sql view model RAW_STAGGING.stg_factures .................... [SUCCESS 1 in 2.00s]
13:19:02  9 of 14 START sql table model RAW_WAREHOUSE.fact_ventes ....................... [RUN]
13:19:02  7 of 14 OK created sql table model RAW_WAREHOUSE.dim_customers ................ [SUCCESS 20 in 1.50s]
13:19:02  6 of 14 OK created sql table model RAW_WAREHOUSE.dim_category ................ [SUCCESS 10 in 1.51s]
13:19:02  10 of 14 START sql table model RAW_WAREHOUSE.fact_factures .................... [RUN]
13:19:02  8 of 14 OK created sql table model RAW_WAREHOUSE.dim_books ..................... [SUCCESS 50 in 0.86s]
13:19:02  9 of 14 OK created sql table model RAW_WAREHOUSE.fact_ventes ................... [SUCCESS 200 in 0.88s]
13:19:02  11 of 14 START sql table model RAW_WAREHOUSE.fact_books_annees ................ [RUN]
13:19:02  12 of 14 START sql table model RAW_WAREHOUSE.fact_books_jour ................... [RUN]
13:19:02  13 of 14 START sql table model RAW_WAREHOUSE.fact_books_mois ................... [RUN]
13:19:03  10 of 14 OK created sql table model RAW_WAREHOUSE.fact_factures ............... [SUCCESS 200 in 0.78s]
13:19:03  14 of 14 START sql table model RAW_MARTS.obt_sales ............................ [RUN]
13:19:03  11 of 14 OK created sql table model RAW_WAREHOUSE.fact_books_annees ........... [SUCCESS 50 in 0.91s]
13:19:03  12 of 14 OK created sql table model RAW_WAREHOUSE.fact_books_jour ............. [SUCCESS 161 in 0.91s]
13:19:03  13 of 14 OK created sql table model RAW_WAREHOUSE.fact_books_mois ............. [SUCCESS 178 in 0.93s]
13:19:04  14 of 14 OK created sql table model RAW_MARTS.obt_sales ....................... [SUCCESS 200 in 1.06s]
13:19:06
13:19:06  Finished running 9 table models, 5 view models in 0 hours 0 minutes and 9.06 seconds (9.06s).
13:19:06
13:19:06  Completed successfully
13:19:06
13:19:06  Done. PASS=14 WARN=0 ERROR=0 SKIP=0 NO-OP=0 TOTAL=14
root@dbt:/usr/app#
```

Figure 2 : Résultat dbt run — 14 modèles SUCCESS en 9.06 secondes

4. Orchestration avec Apache Airflow

Apache Airflow orchestre l'exécution du pipeline DBT via un DAG (Directed Acyclic Graph) qui s'exécute automatiquement tous les jours a 06h00. Airflow est déployé dans un conteneur Docker accessible sur le port 8090.

4.1 Configuration du DAG

Parametre	Valeur
DAG ID	bookshop_dbt_pipeline
Description	Pipeline DBT : RAW -> STAGGING -> WAREHOUSE -> MARTS
Schedule	0 6 * * * (tous les jours a 06h00)
Nombre de taches	14 BashOperator
Retries	1 (delai 3 minutes)
Tags	bookshop, dbt, snowflake

4.2 Graph du DAG — Toutes les taches en succès

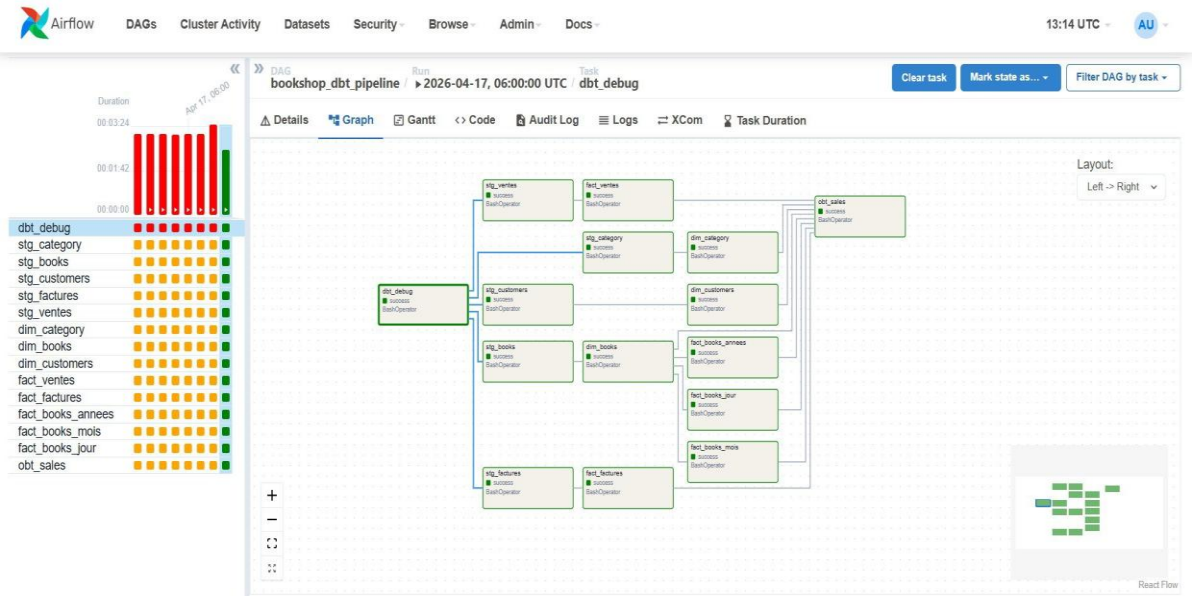

Figure 3 : DAG Airflow — bookshop_dbt_pipeline — toutes les taches SUCCESS (vert)

5. Pipeline d'Ingestion (Touche Personnelle)

En touche personnelle, un pipeline d'ingestion Python a été mis en place pour transférer les données depuis une base PostgreSQL locale vers le schéma RAW de Snowflake.

5.1 Architecture d'ingestion

Etape	Outil	Description
Source	PostgreSQL local	Base bookshop_local avec les 5 tables
Extraction	psycopg2 + pandas	Lecture des tables via SELECT *
Chargement	snowflake-connector	write_pandas() avec overwrite=True
Destination	Snowflake RAW	Schema BOOKSHOP.RAW

6. Dashboard Power BI (Touche Personnelle)

Un dashboard Power BI a été développe et connecté directement à Snowflake via Import. Il contient 5 pages analytiques basées sur les données du schéma MARTS et WAREHOUSE.

Page	Titre	Visualisations
1	Vue Globale	KPIs (CA, Encaisse, Nb ventes, QTE) + CA mensuel + Camembert catégories + Top
2	Clients	Nb clients + Top clients par CA + Top clients par quantité
3	Livres	Ventes par année + CA par livre + Evolution mensuelle
4	Factures	KPIs + Facture vs Paye par mois + Anneau impayés
5	Analyse par Jour	Barres par jour + Camembert QTE par jour

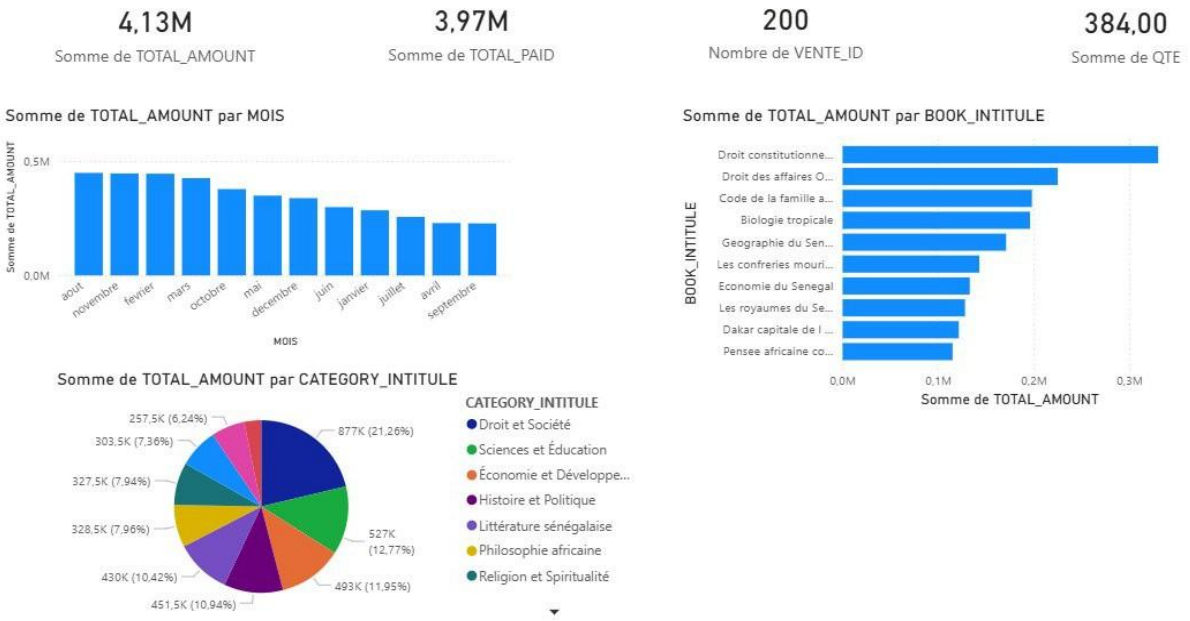

Figure 4 : Dashboard Power BI — Page 1 Vue Globale (CA Total : 4,13M FCFA)

7. Versioning GitHub

Le livrable est versionné sur GitHub et accessible publiquement. Le repository contient incluant les livrables officiels : rapport PDF, présentation PowerPoint et vidéo de démonstration.

Elément	Détail
Repository	https://github.com/hamdilawo/bookshop-livrables.git
Visibilité	Public
Fichiers code	models/, dags/, dashboard/, ingestion/, docker-compose
Documentation	README.md + GUIDE.md (guide technique complet)
Livrables	**rapport_bookshop.pdf + bookshop_presentation.pptx + video_demo.mp4**

8. Résultats et Conclusion

8.1 Résultats clés

Métrique	Valeur
CA Total génère	**4 130 000 FCFA**
Montant encaisse	**3 970 000 FCFA**
Nombre de ventes	**200 lignes**
Quantité totale vendue	**384 livres**
Modèles DBT	**14 (PASS=14, ERROR=0)**
Tables Snowflake	**18 tables dans 4 schémas**
Pages Power BI	**5 pages analytiques**
Livres catalogues	**50 livres sénégalais**
Clients actifs	**20 clients**

8.2 Conclusion

Ce projet a permis de mettre en place un pipeline Big Data complet et fonctionnel pour une librairie sénégalaise. L'ensemble des composants requis ont été implémentées avec succès : Snowflake comme data warehouse cloud, DBT pour les transformations SQL en couches successives, Apache Airflow pour l'orchestration via un DAG quotidien, et Power BI pour la visualisation des données analytiques.

En touche personnelle, un pipeline d'ingestion Python a été développe pour alimenter Snowflake depuis PostgreSQL, et un versioning du livrable a été fait sur Github. L'ensemble du projet — code source, livrables (PDF, PowerPoint, vidéo) et documentation — est versionne sur GitHub avec un README et un GUIDE technique complets.

Projet réalise par Hamady Ngansou SABALY, Ousmane SOW et Doudou Malick FAYE

Master Intelligence Artificielle — Dakar Institute of Technology — 2025/2026

Enseignant : Patrick NGOUNE